# Angewandte Regression — Musterlösungen zur Serie 5

### 1. a) Ohne Variablenselektion:

summary (modback)

```
R-Code:
   d.concept <- read.table("http://stat.ethz.ch/Teaching/Datasets/</pre>
               WBL/concept.dat", header=TRUE)
   attach(d.concept)
   model1 <- regr(gpa~iq+alter+sex+total+c1+c2+c3+c4+c5+c6, data=d.concept)</pre>
   summary(model1)
   R-Output:
   regr(formula = gpa ~ iq + alter + sex + total + c1 + c2 + c3 +
      c4 + c5 + c6, data = d.concept)
  Fitting function lm
  Terms:
                     coef
                               stcoef
                                          signif R2.x df p.value
   (Intercept) 2.520984023 0.000000000 0.27199074
                                                  NA 1 0.5890
               0.073390658 0.460395291 2.09481514 0.2898 1 0.0001
   alter
              -0.410205964 -0.123711419 -0.70381025 0.1120 1 0.1647
              -0.575292611 -0.134957849 -0.73019102 0.1555 1 0.1497
   sex
   total
              -0.066639252 -0.393960015 -0.56869311 0.7747 1 0.2604
              0.188234182  0.255619950  0.84927309  0.4814  1  0.0947
   c1
   c2
              0.128613669 0.233979733 0.72342766 0.5174 1 0.1534
   сЗ
              0.122059074 0.200728570 0.64017323 0.5022 1 0.2057
   c4
              -0.003138792 -0.004392463 -0.01386129 0.5074 1 0.9780
   с5
              с6
               St.dev.error: 1.441 on 67 degrees of freedom
  Multiple R^2: 0.5903 Adjusted R-squared: 0.5291
  F-statistic: 9.653 on 10 and 67 d.f., p.value: 9.589e-10
  Factor(s) with two levels converted to 0-1 variable(s):
    sex
  0 "1"
  1 "2"
   Mit multipler Regression stellt sich der ig als signifikant heraus.
b) Mit Variablenselektion:
   R-Code:
   stepback <- step(model1,direction="backward")</pre>
   formula(stepback)
   modback <- regr(formula(stepback),data=d.concept)</pre>
```

### (19.10.07) — Angewandte Regression — Musterlösungen zur Serie 5 —

Wenn man den obigen R-Code ausführt, sieht man, dass Variablen im Modell aufgenommen werden, jedoch stellt sich immer der iq als signifikant heraus.

# R-Output:

```
Call:
```

```
regr(formula = formula(stepback), data = d.concept)
Fitting function lm
```

#### Terms:

```
coef
                        stcoef
                                  signif R2.x df p.value
(Intercept) 2.47444426 0.0000000 0.2721850
                                           NA 1 0.5889
           0.07352652  0.4612476  2.2631592  0.2457  1  0.0000
alter
          -0.40666273 -0.1226428 -0.7167479 0.1015
          -0.57485722 -0.1348557 -0.7701066 0.1221 1 0.1290
sex
total
          -0.06493277 -0.3838716 -0.7434638 0.7022 1 0.1426
           0.18921701 0.2569546 0.9248499 0.4467 1 0.0693
c1
c2
           с3
           0.12419305 0.2042379 0.6973449 0.4751 1 0.1686
           0.14315563  0.1963707  0.6998099  0.4521  1  0.1672
с5
```

St.dev.error: 1.42 on 69 degrees of freedom Multiple R^2: 0.5902 Adjusted R-squared: 0.5427

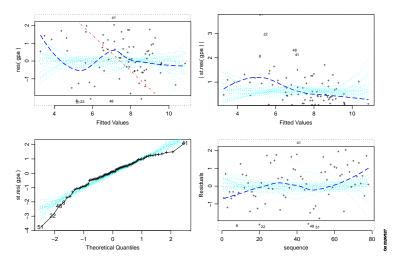
F-statistic: 12.42 on 8 and 69 d.f., p.value: 7.587e-11

Factor(s) with two levels converted to 0-1 variable(s):
 sex
0 "1"

0 "1" 1 "2"

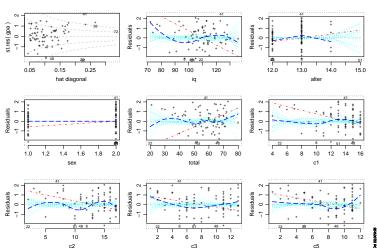
# c) plot(modback)

#### Modell - backwards



 $_{\rm Es}$ 

#### Modell - backwards



Man sieht keine wirklichen Ausreisser. Transformationen sind keine nötig.

d) Wir betrachten die folgenden Residual-plots zweier Eingangsvariablen:

```
plres2x(~ iq + alter,modback)
plres2x(~ iq + c1,modback)
plres2x(~ iq + total,modback)
plres2x(~ sex + total, modback)
plres2x( ~ sex + c2, modback)
plres2x(~ c3 + c5,modback)
```

residuals ~ in + c1 residuals - sex + tota 8 5

sieht nicht nach Wechselwirkungen in den ersten beiden Plots aus.

```
e) R-Code:
```

(19.10.07)

```
add1.regr(modback)
R-Output:
```

Single term additions

```
Model:
gpa ~ iq + alter + sex + total + c1 + c2 + c3 + c5
           Df Sum of Sq
RSS
        AIC F value
                        Pr(F)
<none>
                        139.090 63.116
I(iq^2)
                  4.154 134.935 62.751 2.0935 0.1525210
I(alter^2)
           1
                 22.476 116.614 51.368 13.1061 0.0005618 ***
I(total^2)
                  0.416 138.673 64.882 0.2040 0.6529275
I(c1^2)
                  0.054 139.035 65.085
                                        0.0266 0.8710275
I(c2^2)
                  0.007 139.082 65.112 0.0035 0.9532760
I(c3^2)
                  6.397 132.693 61.444 3.2782 0.0746258
I(c5^2)
                  3.168 135.922 63.319 1.5849 0.2123615
iq:alter
                  0.099 138.991 65.060
                                        0.0484 0.8264768
iq:sex
            1
                  1.376 137.713 64.340
                                        0.6795 0.4126481
iq:total
            1
                  5.983 133.107 61.686
                                        3.0564 0.0849307
iq:c1
                  0.561 138.528 64.800
                                        0.2756 0.6013222
                  3.857 135.233 62.922 1.9394 0.1682753
iq:c2
iq:c3
                  0.936 138.153 64.589
                                        0.4609 0.4995198
iq:c5
                  0.019 139.070 65.105
                                        0.0094 0.9231646
alter:sex
                  0.304 138.785
                                64.945
                                        0.1491 0.7006489
                  0.850 138.240
                                64.638
                                        0.4180 0.5201130
alter:total
                  0.671 138.418 64.739
                                        0.3297 0.5677023
alter:c1
alter:c2
                  1.557 137.532 64.238
                                        0.7700 0.3833105
alter:c3
                  0.034 139.055 65.097 0.0167 0.8975330
                  0.293 138.796 64.951 0.1437 0.7058409
alter:c5
                  7.869 131.221 60.574 4.0776 0.0474005 *
sex:total
           - 1
                  4.866 134.224 62.338 2.4650 0.1210515
sex:c1
                  8.309 130.781
                                60.311 4.3203 0.0414373 *
sex:c2
                  2.084 137.005 63.938
                                        1.0346 0.3126920
sex:c3
            1
                  4.623 134.467 62.480 2.3376 0.1309200
sex:c5
            1
                  1.584 137.506 64.223 0.7832 0.3792894
total:c1
total:c2
                  0.068 139.022 65.078
                                        0.0331 0.8561746
total:c3
                  2.410 136.680 63.753
                                        1.1990 0.2773843
                  0.540 138.549 64.812 0.2653 0.6081950
total:c5
c1:c2
                  2.032 137.057 63.968
                                        1.0084 0.3188515
c1:c3
                  1.281 137.809
                                64.394
                                        0.6319 0.4294122
c1:c5
                  2.354 136.735 63.784
                                        1.1708 0.2830593
c2:c3
                  0.904 138.185 64.607 0.4450 0.5069865
c2:c5
                  0.395 138.694 64.894 0.1937 0.6612543
c3:c5
                  7.054 132.036 61.056 3.6327 0.0608820 .
Signif. codes: 0 '***, 0.001 '**, 0.01 '*, 0.05 '., 0.1 ', 1
```

f) Wir nehmen das volle lineare Modell mit den signifikanten quadratischen Termen und Wechselwirkungen:

```
model2 <- regr(gpa~iq+alter+sex+total+c1+c2+c3+c4+c5+c6</pre>
          +I(alter^2)+I(c3^2)+iq:total+sex:total+sex:c2+c3:c5, data=d.concept)
summary(model2)
stepback <- step(model2,direction="backward")</pre>
formula(stepback)
```

modback <- regr(formula(stepback),data=d.concept)</pre>

summary (modback)

Mit der backward-analyse erhalten wir:

> Call:

regr(formula = formula(stepback), data = d.concept)

Fitting function lm

Terms:

```
coef
                           stcoef
                                     signif R2.x df p.value
(Intercept) -1.348058e+02 0.0000000 -1.7432472
                                                NA 1 0.0009
          -2.177437e-02 -0.1365953 -0.2030645 0.7985 1 0.6865
alter
           2.270072e+01 6.8461658 1.8900714 0.9626 1 0.0003
sex
           -2.433626e+00 -0.5709041 -0.8427025 0.7999 1 0.0972
           -2.888571e-01 -1.7076746 -1.3323839 0.8942 1 0.0098
total
c1
           2.213165e-01 0.3005454 1.2070279 0.4556 1 0.0188
c2
           1.124524e-01 0.2045784 0.7501769 0.5029 1 0.1390
с5
           1.661921e-01 0.2279705 0.9065870 0.4609 1 0.0748
I(alter^2) -8.942918e-01 -6.9758117 -1.9272515 0.9625 1 0.0003
I(c3^2)
           7.318765e-03 0.1903856 0.7930607 0.4353 1 0.1181
iq:total
          1.829685e-03 1.5601484 0.9597051 0.9166 1 0.0597
sex:total 3.335942e-02 0.4776021 0.6676067 0.8105 1 0.1871
```

St.dev.error: 1.251 on 66 degrees of freedom Multiple R^2: 0.6957 Adjusted R-squared: 0.645

F-statistic: 13.72 on 11 and 66 d.f., p.value: 3.417e-13

Ausreisser: keine.

Transformationen: keine nötig

Wichtig: Datensatz mit detach(concept) wieder abhängen!

### 2. a) Schrittweise rückwärts: Wir betrachten das volle Modell

```
\log(\text{RUT}) = \beta_0 + \beta_1 \log(\text{VISC}) + \beta_2 \text{ ASPH} + \beta_3 \text{ BASE} + \beta_4 \text{ FINES} + \beta_5 \text{ VOIDS} + \beta_6 \text{ RUN}
```

und eliminieren schrittweise die am wenigsten signifikante Variable

> r.bw <- step(r.asp, direction="backward")

Start: AIC=-129

log10(RUT) ~ log10(VISC) + ASPH + BASE + FINES + VOIDS + RUN

	Df	Sum of Sq	RSS	AIC					
- FINES	1	0.0039	0.3	-130.7					
- BASE	1	0.0065	0.3	-130.4					
<none></none>			0.3	-129.1					
- RUN	1	0.1	0.4	-125.8					
- VOIDS	1	0.1	0.4	-121.9					
- ASPH	1	0.2	0.5	-113.2					
- log10(VISC)	1	0.6	0.9	-96.4					
Step: AIC=-131									
log10(RUT) ~ 1	log1	LO(VISC) +	ASPH +	BASE +					

S

VOIDS + RUN 1

```
RSS AIC
            Df Sum of Sq
- BASE
                  0.012
                          0.3 -131.5
<none>
                          0.3 -130.7
- RUN
                    0.1
                          0.4 -127.7
- VOIDS
             1
                    0.1 0.4 -121.8
- ASPH
                    0.2 0.6 -114.7
```

```
(19.10.07)
                 — Angewandte Regression — Musterlösungen zur Serie 5 —
      - log10(VISC) 1
                            0.7 1.0 -96.6
      regr(formula = log10(RUT) ~ log10(VISC) + ASPH + VOIDS + RUN,
      Terms:
                    coef stcoef signif R2.x df p.value
       (Intercept) -1.742 0.000 -1.31 NA 1 0.012
      log10(VISC) -0.547 -0.852 -4.07 0.671 1 0.000
      ASPH
                   0.465 0.166 2.11 0.124 1 0.000
      VOIDS
                   0.144 0.137 1.56 0.216 1 0.004
      RUN
                  -0.222 -0.186 -0.91 0.663 1 0.073
      St.dev.error: 0.111 on 26 degrees of freedom
      Multiple R^2: 0.971 Adjusted R-squared: 0.966
      F-statistic: 216 on 4 and 26 d.f., p.value:
      Das Endmodell lautet mit schrittweiser Variablenselektion rückwärts:
                   \log(\text{RUT}) = \beta_0 + \beta_1 \log(\text{VISC}) + \beta_2 \text{ ASPH} + \beta_3 \text{ VOIDS} + \beta_4 \text{ RUN}.
      Schrittweise vorwärts: Wir betrachten das Modell log(RUT) = \beta_0 und fügen schritt-
       weise die signifikanteste der verbleibenden Variable hinzu.
      > r.start <- regr(log10(RUT) ~ 1, data = d.asp)</pre>
      > r.fw <- step(r.start, scope = formula(r.asp), direction="forward")
      Start: AIC=-29.9
      log10(RUT) ~ 1
                    Df Sum of Sq
                                   RSS
       + log10(VISC) 1
                           10.5
                                   0.6 -118.0
                                   1.5 -89.4
      + RUN
                            9.5
                    1
      + VOIDS
                            1.9 9.2 -33.7
                    1
      + FINES
                    1
                            1.1 9.9 -31.3
       <none>
                                  11.1 -30.0
       + BASE
                            0.4 10.7 -29.1
                    1
      + ASPH
                            0.3 10.8 -28.7
      Step: AIC=-118
      log10(RUT) ~ log10(VISC)
                             RSS AIC
              Df Sum of Sq
      + ASPH 1
                      0.1
                             0.5 -122.0
       <none>
                              0.6 -118.0
      + VOIDS 1 0.0298
                             0.6 -117.6
      + RUN 1
                   0.0231
                             0.6 -117.2
      + FINES 1 0.0084
                             0.6 -116.4
      + BASE 1 0.0055
                             0.6 -116.3
         . . .
      Step: AIC=-131
      log10(RUT) ~ log10(VISC) + ASPH + VOIDS + RUN
                             RSS AIC
              Df Sum of Sq
       <none>
                             0.3 -131.5
      + BASE 1 0.0122
                             0.3 -130.7
```

+ FINES 1 0.0096

> summary(r.fw)

Call:

0.3 -130.4

b) All Subsets: Wir berechnen alle möglichen Untermodelle und untersuchen die besten Modelle mit einer, zwei, drei, ... Variablen. Wir suchen uns diejenigen Modelle mit den kleinsten Cp-Werten.

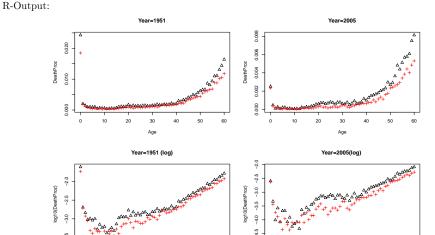
```
> library(leaps)
> r.allsub <- regsubsets(log10(RUT)~log10(VISC)+ ASPH + BASE + FINES
                       + VOIDS + RUN, data=d.asp, nbest=2)
> r.allsub <- regsubsets(formula(r.asp), data=d.asp, nbest=2)
> summary(r.allsub)
Subset selection object
Call: regsubsets.formula(formula(r.asp), data = d.asp, nbest = 2)
6 Variables (and intercept)
           Forced in Forced out
log10(VISC)
              FALSE
                         FALSE
ASPH
               FALSE
                          FALSE
BASE
               FALSE
                          FALSE
FINES
               FALSE
                         FALSE
VOTES
               FALSE
                         FALSE
               FALSE
                         FALSE
2 subsets of each size up to 6
Selection Algorithm: exhaustive
        log10(VISC) ASPH BASE FINES VOIDS RUN
1 (1) "*"
1 (2)""
2 (1) "*"
2 (2) "*"
3 (1) "*"
3 (2) "*"
4 (1) "*"
4 (2) "*"
5 (1) "*"
5 (2) "*"
6 (1) "*"
> r.cp <- summary(r.allsub)$cp
> names(r.cp) <- c(t(outer(1:5, 1:2, paste, sep=".")), 6.1)
> cat("\n Cp-Wert für Modell x.v \n")
 Cp-Wert für Modell x.y
> r.cp
 1.1 1.2 2.1 2.2 3.1 3.2 4.1 4.2 5.1 5.2 6.1
20.33 91.96 13.98 20.00 5.66 12.21 4.26 7.44 5.30 5.51 7.00
```

Das Endmodell lautet mit schrittweiser Variablenselektion vorwärts gleich wie das Endmodell der rückwärts Variablenselektion. Auch bei der All Subset Methode ist dieses Modell (Modell 4.1) das beste, gemessen am Cp-Wert.

(19.10.07) — Angewandte Regression — Musterlösungen zur Serie 5 —

Bemerkung: Das Resultat der Forward-Methode kann deutlich verschieden von der Backward-Methode sein, welche der Forward-Methode in der Regel vorzuziehen ist. Falls einige erklärende Variablen stark miteinander korreliert sind, können sich die besten Modelle je nach Verfahren unterscheiden.

## **3. a)** R-Code:



### Bemerkung:

- Die Sterbewahrscheinlichkeiten sind im Jahr 2005 bedeutend kleiner als im Jahr 1951.
- Wir werden sehr wahrscheinlich Schwierigkeiten bekommen in der linearen Modellierung für das ganze Specktrum, da im Alter zwischen 0 und 10 die Sterbewahrscheinlichkeiten stark sinken, zwischen 10 und 20 wieder steigen, zwischen 20 und 30 Konstant bleibend (sogar leicht fallend) und im höheren alter wieder monoton steigend.

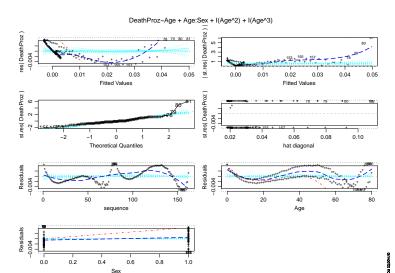
# b) Die finallen Modelle sind:

1 "1"

Residuen-Analyse:

```
d.mort1 <- d.mort0[(d.mort0$Year==2005),]</pre>
 • Modell 1: für das nicht-transformiertes Modell erhalten wir:
  R-Code:
   r.mort1 <- regr(formula=DeathProz~Age+Sex,data=d.mort1)</pre>
   add1.regr(r.mort1)
   r.mort1 <- regr(formula=DeathProz~Age*Sex+I(Age^2)*Sex
                   +I(Age^3)*Sex,data=d.mort1)
   summary(r.mort1)
   R-Output:
   > add1.regr(r.mort1)
   Single term additions
   Model:
   DeathProz ~ Age + Sex
                                      AIC F value Pr(F)
           Df Sum of Sq
   <none>
                            0.07 -2719.31
   I(Age^2) 1
                   0.04
                            0.04 -2949.73 335.677 < 2e-16 ***
   Age:Sex 1 0.0007654
                           0.07 -2720.78 3.437 0.06467 .
   Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '.' 0.1 ' 1
   > summary(r.mort1)
   regr(formula = DeathProz ~ Age * Sex + I(Age^2) * Sex + I(Age^3) *
       Sex, data = d.mort1)
   Fitting function lm
   Terms:
                        coef
                                  stcoef
                                            signif R2.x df p.value
   (Intercept) -3.932926e-03 0.00000000 -1.9056321
                                                       NA 1 0.0002
   Age
                9.650666e-04 1.83489999 4.2927984 0.9274 1 0.0000
   Sex
                1.892865e-03 0.07696326 0.6485268 0.7383 1 0.2021
   I(Age^2)
                -4.225177e-05 -6.64258366 -6.4476179 0.9699 1 0.0000
   I(Age^3)
                4.965719e-07 5.96613934 9.2252527 0.9520 1 0.0000
                -4.376591e-04 -0.92351696 -1.3765887 0.9537 1 0.0073
   Sex:I(Age^2) 1.865965e-05 2.63731918 2.0134596 0.9763 1 0.0001
   Sex:I(Age^3) -2.139609e-07 -2.13900399 -2.8107060 0.9592 1 0.0000
   St.dev.error: 0.00246 on 154 degrees of freedom
   Multiple R^2: 0.9619 Adjusted R-squared: 0.9602
   F-statistic: 556.2 on 7 and 154 d.f., p.value:
   Factor(s) with two levels converted to 0-1 variable(s):
     Sex
   0 "0"
```

— Angewandte Regression — Musterlösungen zur Serie 5 —



Beobachtung: Die Residuen-Analyse bekräftigt, dass das Modell alle wesentlichen Voraussetzungen nicht erfüllt.

• Modell 2: für das Log-transformiertes Modell

```
R-Code:
r.mort2 <- regr(formula=log(DeathProz)~Age+Sex,data=d.mort1)</pre>
add1.regr(r.mort2)
r.mort2 <- regr(formula=log(DeathProz)~Age*Sex+I(Age^2)*Sex
                       +I(Age^3)*Sex,data=d.mort1)
summary(r.mort2)
R-Output:
> add1.regr(r.mort2)
Single term additions
Model:
log(DeathProz) ~ Age + Sex
                         RSS
                                  AIC F value Pr(F)
                      239.994 -91.242
<none>
I(Age^2) 1
             61.613 178.381 -185.370 110.5281 <2e-16 ***
Age:Sex 1 0.353 239.640 -89.720 0.4719 0.4926
```

Signif. codes: 0 '\*\*\* 0.001 '\*\* 0.01 '\* 0.05 '.' 0.1 ' 1

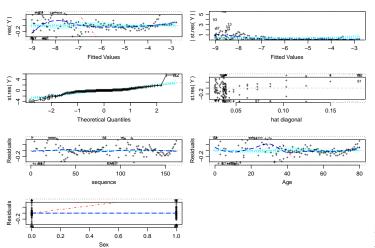
> summary(r.mort2)

Terms:

	coef	stcoef	signif	R2.x	df	p.value
(Intercept)	-8.548668e+00	0.00000000	-20.14427495	NA	1	0.0000
Age	-4.195296e-03	-0.05056388	-0.09075607	0.9274	1	0.8579
Sex	-8.569355e-02	-0.02208689	-0.14278623	0.7383	1	0.7783

11

log(DeathProz)~Age \* Sex + I(Age^2) \* Sex + I(Age^3) \* Sex



Sex
Beobachtung: Dieses Modell scheint besser zu sein, ist aber auch nicht ganz überzeugend.

# Verbesserungsvorschläge:

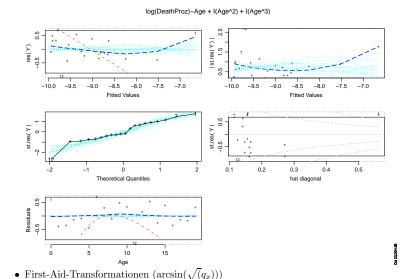
Residuen-Analyse:

- Mann und Frau getrennt anschauen
- Was zu Beginn betreffend den möglichen Schwierigkeiten schon vermutet wurde, hat sich in den Residuden-Analyse bestätigt. Es scheint angebracht, zusätzliche drei Modell zu machen, Alter zwischen 0 und 20, Alter zwischen 20 und 30, Alter grösser als 30.

Als Beispiel betrachten wir den Altersbereich 0 bis 20 für Frauen (Log-Modell). Wir erhalten ein nicht fertiges Modell, das die Voraussetzungen besser erfüllt:

```
d.mort3 <- d.mort1[(d.mort1$Gender==1)&(d.mort1$Age<=19),]
r.mort3 <- regr(formula=log(DeathProz)~Age+I(Age^2)+I(Age^3),data=d.mort3)
summary(r.mort3)</pre>
```

Residuen-Analyse:



• andere Regressionstechniken