

Angewandte Regression — Musterlösungen zur Serie 11

1. a) Diese Aufgabe haben wir schon in der letzten Serie gemacht. Diesesmal betützen wir `regr()`.

```
d.mental <- read.table("http://stat.ethz.ch/Teaching/Datasets/WBL/mental.dat", head=1)
d.mental$Y2 <- ordered(d.mental$Y, levels=c("Well", "Mild", "Moderate", "Impaired"))
r.mantel <- regr(Y2~SES+LE, data=d.mental, family="ordered")
summary(r.mantel)
```

> Call:

```
regr(formula = Y2 ~ SES + LE, data = d.mental, family = "ordered")
Fitting function polr
```

Terms:

	coef	stcoef	signif	R2.x	df	p.value
SES	-1.111	-0.560	-0.896	NA	1	0.064
LE	0.319	0.872	1.298	NA	1	0.005

Intercepts:

	Value	Std. Error
Well Mild	-0.282	0.642
Mild Moderate	1.213	0.661
Moderate Impaired	2.209	0.721

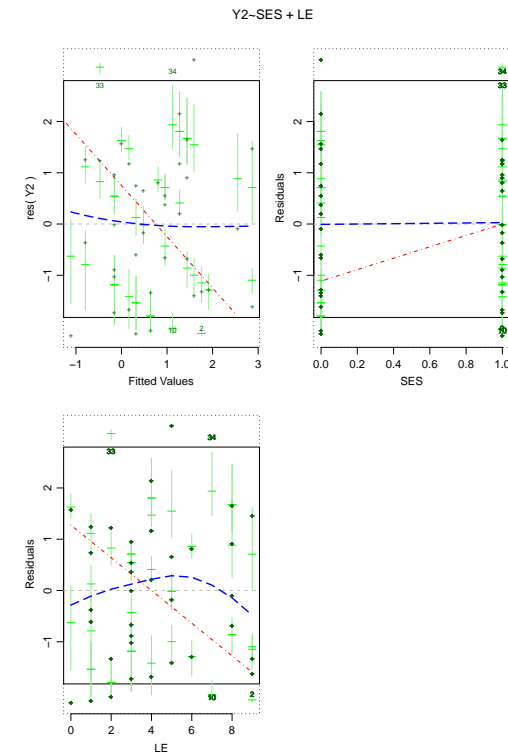
Family is ordered. Dispersion parameter taken to be 1.

AIC: NULL

Factor(s) with two levels converted to 0-1 variable(s):

```
SES
0 "0"
1 "1"
```

- b) Die Residuenplots



sind akzeptabel:

- die Glättungskurve im TA ist fast mit der Nulllinie identisch.
- die Glättungskurve im LE-Residuen-Plot ist nach unten gekrümmt, aber kann als akzeptabel betrachtet werden.

2. Die Daten werden eingelesen:

```
d.kevlar <- read.table("http://stat.ethz.ch/Teaching/Datasets/WBL/kevlar49.dat", header=T)
d.kevlar$Spool <- factor(d.kevlar$Spool)
d.kevlar <- d.kevlar[d.kevlar$Stress>=24,]
```

```
a) l.kevlar <- regr(log(Failure)~Stress+Spool, data=d.kevlar)
summary(l.kevlar)
plot(l.kevlar)
```

> Call:

```
regr(formula = log(Failure) ~ Stress + Spool, data = d.kevlar)
```

Fitting function lm

Terms:

	coef	stcoef	signif	R2.x	df	p.value
(Intercept)	33.216	0.000	8.27	NA	1	0
Stress	-0.924	-0.662	-6.49	0.060	1	0
Spool	NA	NA	7.27	0.009	7	0

Coefficients for factors:

\$Spool

	1	2	3	4	5	6	7	8
	0.000	-2.192	-3.027	0.531	-1.726	-1.878	-3.415	-0.585

St.dev.error: 1.1 on 78 degrees of freedom

Multiple R²: 0.819 Adjusted R-squared: 0.8

F-statistic: 44.1 on 8 and 78 d.f., p.value: 0

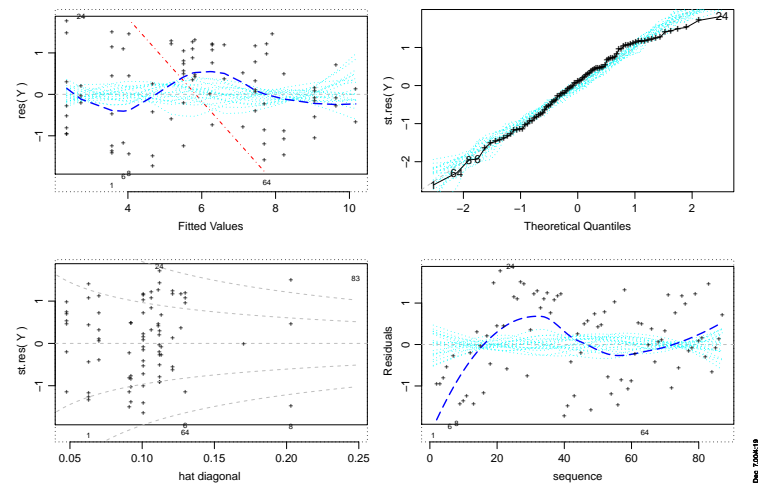
Alle Eingangsvariablen sind signifikant.

Residuenanalyse:

- TA: die Glättungskurve ist eine Wellenlinie
- Streuungsdiagramm: die Glättungskurve ist fallend
- QQ-Plot: der QQ-Plot passt nicht optimal, ist eher kurzschwänziger
- Leverage-Plot: wenige Daten haben einen grösseren Hebelarm.
- Unabhängigkeit: ist verletzt
- Eingangsvariablen-Residuen: akzeptabel

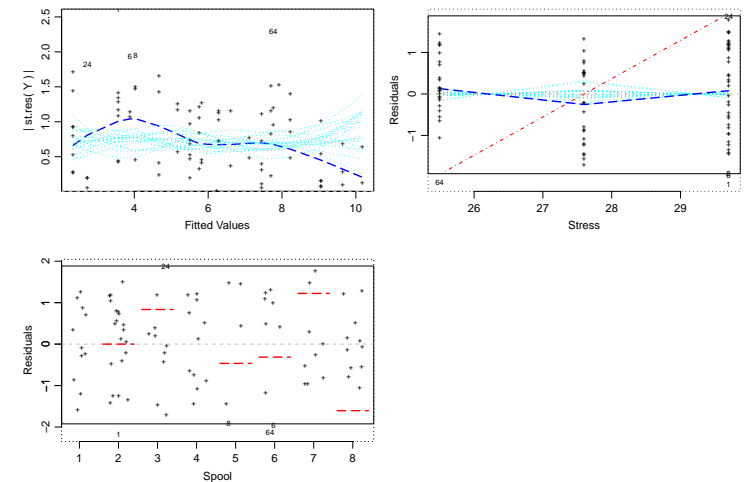
Die Annahmen nicht erfüllt.

Residual Analyse 1



Der 7.12.09


Residual Analyse 2



Der 7.12.09

b) Die empirische Survival-Funktion $\hat{S}(x)$ lässt sich zb wie folgt bestimmen

```
d.kevlar$index <- 1
g.kelvar <- split(d.kevlar,d.kevlar$Stress)
h.kevlar1 <- NULL
h.kevlar1<-cumsum(g.kelvar$'29.7'$index)/length(g.kelvar$'29.7'$index)
h.kevlar1<-c(h.kevlar1,cumsum(g.kelvar$'27.6'$index)/
length(g.kelvar$'27.6'$index))
h.kevlar1<- c(h.kevlar1,cumsum(g.kelvar$'25.5'$index)/
length(g.kelvar$'25.5'$index))
d.kevlar$survprop <- 1-h.kevlar1
Den Plot machen wir mit
plot(~log(Failure)+log(-log(survprop)),data=d.kevlar,
pch=as.numeric(as.factor(Stress)))
```



```
c) r.kevlar <- survreg(Surv(Failure,rep(1,nrow(d.kevlar)))~Stress+Spool,
  data=d.kevlar)
summary(r.kevlar)
```

```
> Call:
survreg(formula = Surv(Failure, rep(1, nrow(d.kevlar))) ~ Stress +
  Spool, data = d.kevlar)
```

	Value	Std. Error	z	p
(Intercept)	31.087	1.5214	20.43	8.42e-93
Stress	-0.835	0.0532	-15.71	1.21e-55
Spool2	-2.051	0.3181	-6.45	1.14e-10
Spool3	-2.812	0.3708	-7.58	3.37e-14
Spool4	0.534	0.3622	1.47	1.41e-01
Spool5	-1.245	0.4589	-2.71	6.67e-03
Spool6	-1.507	0.3866	-3.90	9.69e-05
Spool7	-3.296	0.3853	-8.55	1.19e-17
Spool8	-0.618	0.3617	-1.71	8.74e-02
Log(scale)	-0.167	0.0868	-1.92	5.44e-02

Scale= 0.846

Weibull distribution
 Loglik(model)= -631 Loglik(intercept only)= -709
 Chisq= 155 on 8 degrees of freedom, p= 0
 Number of Newton-Raphson Iterations: 7
 n= 87
 Alle Variablen sind signifikant.

d) Wir fassen zusammen (siehe dazu auch Skript 18.1.d ybd 18.1.g):

Lineare-Regression aus a): $\log(\text{Failure}) = \beta_0 + \beta_1 \text{Stress} + \beta_2 \text{Spool} + \epsilon$,
 $\epsilon \sim \text{Standard-Normalverteilung}$

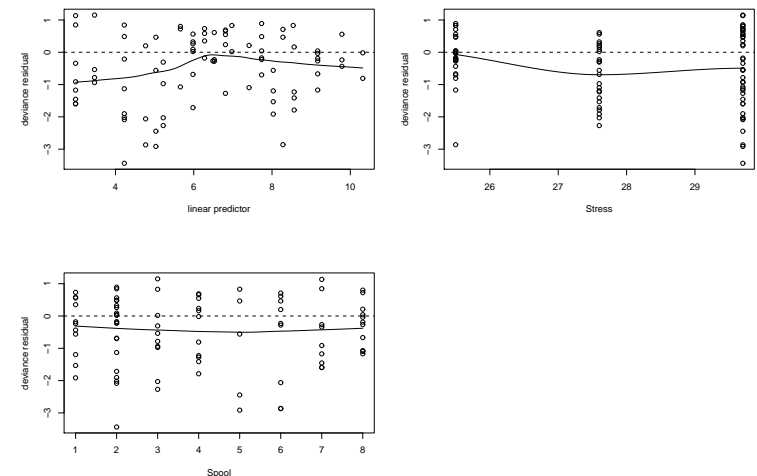
Weibull-Regression: $\log(\text{Failure}) = \beta_0 + \beta_1 \text{Stress} + \beta_2 \text{Spool} + \epsilon$,
 $\epsilon \sim \text{Standard-Gumbel-Regression}$

dh, die beiden Regression unterscheiden sich in der Annahme der Fehlerverteilung.

e) Die Residuenplots

```
par(mfrow=c(2,2))
scatter.smooth(r.kevlar$linear.predictors, residuals(r.kevlar,
  type='deviance')[,"median"], xlab='linear predictor',
  ylab='deviance residual')
abline(h=0, lty=2)
scatter.smooth(d.kevlar$Stress, residuals(r.kevlar, type='deviance')[,"median"],
  xlab='Stress', ylab='deviance residual')
abline(h=0, lty=2)
scatter.smooth(d.kevlar$Spool, residuals(r.kevlar, type='deviance')[,"median"],
  xlab='Spool', ylab='deviance residual')
abline(h=0, lty=2)
```

Die



Glättungskurven sind bedeutend glatter als bei a).

3. a) Da wir am Mittelwert interessiert sind, benützen wir für die Regressionformel $Y \sim 1$:

```
library(MASS)
d.ertrag <- c(35.6, 34.9, 36.0, 30.2, 36.2, 35.6, 35.8, 35.9, 36.1)
```

```
r.ertrag <- rlm(Y~1,data.frame(Y=d.ertrag))
```

```
(s.ertrag <- summary(r.ertrag))
s.mu <- s.ertrag$coefficients[1,1]
s.stdev <- s.ertrag$coefficients[1,2]
t.qt <- qt(0.975,length(d.ertrag)-1)
(r.intervall <- s.mu+c(-1,1)*t.qt*s.stdev)

>
Call: rlm(formula = Y ~ 1, data = data.frame(Y = d.ertrag))
Residuals:
    Min       1Q   Median       3Q      Max
-5.53414 -0.13414  0.06586  0.26586  0.46586

Coefficients:
            Value      Std. Error t value
(Intercept) 35.7341    0.1610    221.9895

Residual standard error: 0.3944 on 8 degrees of freedom
```

```
> [1] 35.36294 36.10535
```

Das klassische 95%-Konfidenzintervall ist viel grösser als das robuste Konfidenzintervall.

```
t.test(d.ertrag)$conf.int
```

```
33.68898 36.59990
```

```
b) plot(d.ertrag)
abline(h=s.mu, lty=1)
abline(h=mean(d.ertrag), lty=2)
```

